PROBLEMA: Análisis de Sentimiento con Scikit-Learn con Multinomial Naive Bayes y/o Gaussian Naive Bayes y/o Bernoulli Naive Bayes.

Trabajaremos con un dataset real para identificar con comentarios sobre **300 películas de IMDB**. Deberéis entregar un **Google Colab Notebook** organizado por secciones que responda a los criterios de evaluación del currículo.

🛠 Paso 1: Importación de Datos

Para agilizar la práctica, utilizaremos la librería kagglehub. Esto nos permite descargar el dataset directamente en el entorno de Colab sin necesidad de subir archivos manualmente.

El dataset con las películas: https://www.kaggle.com/datasets/nick2908/imdb-movie-reviews-for-sentiment-analysis

Importante: Acuérdate de tokenizar los comentarios de las películas, revisa las prácticas anteriores

📋 Criterios de Evaluación (Estructura del Notebook)

Vuestro Notebook debe estar dividido mediante celdas de texto que identifiquen claramente cada criterio:

- **a) Datos etiquetados:** Demostrar que se cargan las columnas de texto y categoría (Spam/Ham).
- **b) Selección de datos (Split):** Uso de train_test_split para separar entrenamiento (train) y prueba (test).
- **c) Fase de entrenamiento:** Construcción del modelo Bayes Naive .
- **d) Fase de validación:** Evaluación inicial de la capacidad de generalización.
- **f) Predicciones:** Crear una función que reciba un texto nuevo y devuelva si es Spam o no.
- **g) Riesgos y sesgos:** Identificar posibles fallos (ej. Falsos Positivos: correos importantes marcados como spam) y cómo minimizarlos (ajuste de umbral de decisión).
- **h) Optimización:** Validación final con el set de test para confirmar que el modelo es robusto.

🏁 Requisito de Entrega Final

La última celda de vuestro notebook debe ejecutar obligatoriamente el siguiente bloque para mostrar vuestros resultados:

```
# 1. Accuracy
print(f"Accuracy Score: {accuracy_score(y_test, y_pred):.2%}")


# 2. Confusion Matrix
print("\n--- Confusion Matrix ---")
cm = confusion_matrix(y_test, y_pred)
print(cm)
```

Bonus: Análisis de modelos

Si has realizado analizado los tres modelos (Gussian Naive Bayes, Bernoulli Naive Bayes y Multinomial Naive Bayes)

Crea una tabla con los valores accuracy_score e identifica el que mejor funciona para este problema. Investiga cual puede ser la causa.

Entrega

Deberéis entregar un **Google Colab Notebook** que contenga:

- **Google Colab Notebook** organizado por secciones que responda a los criterios de evaluación del currículo.
- Sección Bonus (opcional): Será la sección final de Google Colab Notebook con las conclusiones con:
    - Tabla con el nombre del modelo y su accuracy_score
    - print con una variable triple-comillas o algo similar

Importante

- No olvidar poner tú nombre en el fichero PDF y en el Google Colab Notebook
- Facilitar **acceso de modo lectura, al menos, al Google Colab Notebook**